



UNIVERSIDAD DE LA REPÚBLICA
FACULTAD DE INGENIERÍA



Maestría en Ciencia de Datos y Aprendizaje Automático
Introducción a la Ciencia de Datos

Tarea 1

Mateo Trujillo 5196121-1
Nicole Cabot 4868948-8

1. Cargado y Limpieza de Datos

A. Exploración de Datos

Al crear el **data frame**, se puede observar que está compuesto por distintas noticias y por las siguientes columnas:

- **idx**: índice de la fila; es un dato auxiliar del **data frame** utilizado para identificar cada fila.
- **article_idx**: identificador del artículo en la base de datos.
- **date**: fecha de publicación.
- **year**: año de publicación.
- **month**: mes de publicación.
- **day**: día de publicación.
- **author**: autor de la noticia.
- **title**: título de la noticia.
- **article**: contenido del artículo.
- **url**: enlace al artículo.
- **section**: sección a la que pertenece la noticia.
- **publication**: medio o publicación de origen.

Datos faltantes:

Para analizar si existen datos faltantes se ejecuta la siguiente instrucción en Python:

```
df.isna().sum()
```

Este método devuelve la cantidad de valores faltantes (**NaN**) por cada columna del **data frame**, obteniendo los siguientes resultados:

Columna	Cantidad de valores faltantes
idx	0
article_idx	0
date	0
year	0
month	0
day	0
author	11405
title	0
article	1176
url	141
section	10232
publication	141

Tabla 1: Cantidad de valores faltantes por columna

A partir de estos resultados, se puede observar que las columnas **author** y **section** presentan una cantidad significativa de valores faltantes. Asimismo, las columnas **article**, **url** y **publication** también contienen algunos datos ausentes, mientras que el resto de las columnas se encuentran completas.

Problema de calidad de datos:

1. La columna **date**, aparte de poseer datos faltantes en algunos casos, también posee problemas de calidad:
 - datos inválidos que no se pueden transformar al formato fecha **datetime**.
 - formatos distintos:
 - Jan 15, 2018
 - 2018-01-15
 - Algunas fechas indicando la hora y otras no

Por todo esto se utiliza la siguiente instrucción:

```
df['date'] = pd.to_datetime(df['date'], errors='coerce', format='mixed')
```

La función **pd.to_datetime** permite convertir los valores de la columna al tipo **datetime**. El parámetro **format='mixed'** permite que Pandas interprete automáticamente múltiples formatos de fecha dentro de la misma columna. Por otro lado, **errors='coerce'** hace que los valores inválidos o no reconocidos se conviertan en **NaT** (*Not a Time*) en lugar de generar un error, facilitando posteriormente su identificación y tratamiento.

2. La columna **month** se encuentra en formato decimal. Si bien no presenta un problema a la hora de procesar los datos, conceptualmente es incorrecto.

3. Publicaciones con mismo título

Varias veces una misma empresa reutiliza el mismo título cuando la temática es recurrente, por ejemplo: "11 of Our Best Weekend Reads" de **The New York Times** para las publicaciones con `article_idx` 29440 y 9126.

Esto podría suponer un problema si la fuente principal de datos para trabajar es el título de los artículos.

4. Publicaciones con mismo contenido

Se encuentran publicaciones con el mismo campo `article`. Por ejemplo, los artículos con `article_idx` 5483 y 16282.

5. Publicaciones repetidas.

Se encuentran 9 pares de artículos con el mismo campo `date`, `author`, `title` y `article`. A pesar de ser un número casi imperceptible frente a la cantidad total de datos, se presenta como un problema de calidad.

Un ejemplo de esto son los artículos con `article_idx` 1383 y 7151

6. Distribución desbalanceada

Reuters posee muchas más publicaciones que otros, lo que puede introducir sesgos estadísticos en el análisis.

Al analizar la cantidad de artículos por medio de prensa se obtiene la tabla 2. A partir de ella se puede observar que los 5 medios con mayor cantidad de artículos en orden descendiente son: **Reuters**, **The New York Times**, **CNBC**, **The Hill**, **People**.

Medio de prensa	Cantidad de artículos
Reuters	9431
The New York Times	2840
CNBC	2623
The Hill	2349
People	1528
CNN	1446
Refinery 29	1236
Vice	1154
Mashable	1045
Business Insider	660
The Verge	594
TechCrunch	568
TMZ	552
Vox	549
Axios	538
Politico	518
Washington Post	468
Buzzfeed News	376
Gizmodo	329
Economist	303
Wired	231
Fox News	227
Vice News	187
New Republic	145
Hyperallergic	123
New Yorker	52

Tabla 2: Cantidad de artículos por medio de prensa

B. Visualización temporal




Figura 1: Cantidad de artículos por medio a lo largo del tiempo

Análisis del gráfico respecto al tiempo:

- 2016 - 2018: no se notan cambios bruscos en el comportamiento
- Principios de 2018 - Principios de 2019: baja en la cantidad de artículos escritos por Reuters
- Principios 2019 - 2020: mayor cantidad de artículos de Reuters y CNBC
- 2020 - fin: gran crecimiento de Reuters y baja radical de los artículos de People.

Análisis del gráfico respecto al medio:

- People, The Hill y The New York Times presentan un comportamiento bastante constante durante todo el rango temporal
- Reuters supera ampliamente en la cantidad de artículos publicados a las demás empresas, su comportamiento fluctúa mucho con respecto al tiempo, con una baja entre 2018 y 2019 y crecimiento a partir de 2019
- CNBC presenta un crecimiento que luego se estabiliza a partir de 2019

Estos comportamientos se condicen con los factores socio-políticos globales y el enfoque temático general de cada medio.

Principales hechos en ese periodo:

- Impeachment de Trump (1)
 - Septiembre de 2019: inicio formal de la investigación.
 - Septiembre – diciembre de 2019: audiencias públicas.
 - Diciembre de 2019: aprobación del Impeachment en la Cámara de Representantes.
 - Enero de 2020: juicio político en el Senado.
- Covid (2)
 - Diciembre de 2019: aparición de los primeros casos reportados en China.
 - Marzo de 2020: declaración de pandemia por la OMS.

Reuters enfatiza en la cobertura de noticias globales, por lo tanto su gráfico sigue un comportamiento acorde a los hechos previamente mencionados y su implicancia a nivel internacional. **CNBC** se centra en la economía y su comportamiento se explicaría por el análisis del impacto económico de la situación política norteamericana y el Covid.

C. Limpieza de texto y conteo de palabras

Para realizar una mayor cobertura se realizan las siguientes extensiones a la función `cleanText()`:

- Se agregan signos de puntuación ([, (,), ", !, ;, -, /) faltantes para una limpieza más completa del texto. No se remueve el . considerando que se podría utilizar en abreviaciones geopolíticas como U.S (United States) o U.N (United Nations).
- Se expanden contracciones frecuentes del inglés (por ejemplo, “don’t” → “do not”) para preservar mejor el significado semántico.
- Se eliminan espacios múltiples generados durante la limpieza del texto.
- Se eliminan espacios al inicio y final de cada texto para mejorar la consistencia.

De esta manera, si se aplica la función al campo `article`, se ve la transformación (a modo de ejemplo):

"The head of the Centers for Medicare and Medicaid Services said Monday it's time that health care" a "the head of the centers for medicare

and medicaid services said monday it is time that health care".

Una posible mejora sería identificar y eliminar plantillas o estructuras repetidas utilizadas por cada medio de prensa, con el objetivo de reducir sesgos y evitar que el modelo aprenda patrones asociados al formato del medio en lugar del contenido de la noticia.

D. Elección de campos de texto

Resulta conveniente utilizar una combinación del título y el cuerpo del artículo.

El título proporciona una síntesis clara del tema principal, aunque por sí solo puede resultar demasiado ambiguo o limitado. A su vez como fue explicado en la parte 1b, hay muchos artículos con el mismo título.

Por otro lado, el cuerpo del texto, si bien puede introducir cierta cantidad de ruido, aporta contexto y detalles relevantes necesarios para un análisis más completo del dataset.

Utilizando ambos campos se obtiene una representación textual más completa del contenido de cada noticia, lo que podría resultar de mayor utilidad al momento de clasificar.

E. Pistas que identifican al medio de prensa

Efectivamente en el dataset aparecen múltiples pistas que permiten identificar de manera directa el medio de prensa al que pertenece un artículo.

En primer lugar la URL de todas las publicaciones indican el medio de prensa de forma directa.

A su vez, el formato de la fecha da una indicación pues cada medio utiliza un formato específico.

También se observan patrones característicos en los títulos y cuerpos de las noticias:

- **Reuters:** resulta evidente el uso de ciertas plantillas repetidas en los títulos y en el cuerpo de los artículos. En varios casos aparece la palabra "BRIEF" en el título y una indicación de fecha o lugar seguida por "(Reuters -)" en el texto principal.

A modo de verificar esta observación, se obtuvieron los siguientes resultados:

- Número total de artículos de **Reuters**: 9431
 - Número de artículos que contienen la palabra "Reuters" en el cuerpo: 8724
 - Número de artículos con la palabra "BRIEF" en el título: 2375
- **People:** este medio parece enfocarse principalmente en noticias sobre personas famosas, y muchos de sus títulos comienzan con el nombre y apellido

de la persona en cuestión o con expresiones como “How” o “When”, seguidas del nombre de la celebridad.

Podría ser conveniente eliminar estas palabras si el objetivo es entrenar un clasificador. De lo contrario, el modelo podría asociar automáticamente estos términos con determinados medios de prensa y basar sus predicciones principalmente en estas pistas, en lugar de aprender características más representativas como el estilo de redacción, la estructura o el vocabulario general de los artículos. En el caso de **Reuters**, esta consideración resulta especialmente importante, ya que existen palabras y estructuras muy características del medio, como “Reuters” o “BRIEF”, que podrían llevar al problema anterior.

F. Restricción por sección o período temporal

Si nuestro objetivo es crear un clasificador, puede ser conveniente distinguir los artículos por temática o período temporal.

Algunos medios centran sus publicaciones en determinadas temáticas. Un ejemplo de lo anterior es **The Hill** que tiene un fuerte enfoque en noticias políticas. Si no se realiza una distinción temática, el clasificador podría sesgarse y asociar automáticamente ciertos temas con un medio específico.

También podrían existir medios que no hayan publicado artículos durante determinados períodos temporales o, por el contrario, medios que hayan concentrado una gran cantidad de publicaciones en un mismo intervalo de tiempo. Esto podría provocar que el clasificador asocie ciertos períodos temporales con medios específicos.

Trabajar realizando estas distinciones ayudaría a reducir estos sesgos, ya que disminuiría la posibilidad de asociar un medio únicamente con una temática o período de publicación. Además, permitiría que el clasificador identifique a los medios basándose en características más representativas, como el vocabulario utilizado, el estilo de redacción o la estructura de los artículos.

Por otro lado, aplicar estas restricciones implicaría trabajar con una menor cantidad de artículos. Si el objetivo es entrenar un clasificador, esto podría resultar perjudicial, ya que la cantidad y diversidad de datos disponibles influye directamente en la calidad del entrenamiento.

En consecuencia, lo ideal sería comparar artículos de una misma temática o período temporal siempre que se disponga de una cantidad suficiente de datos para cada categoría y período temporal considerado.

2. Conteo de Palabras y visualizaciones

A. Palabras más frecuentes por medio

En esta sección, se utiliza la librería `wordcloud`. Esta permite generar visualizaciones en forma de nube de las palabras más frecuentes en un texto.

Se procesan los artículos de los cinco medios con mayor cantidad de publicaciones, identificados en la Parte 1A. Se crea una nube de palabras más frecuentes

para cada uno de estos medios, se obtienen los resultados de las figuras 2, 3, 4, 5 y 6. En estas visualizaciones, el tamaño de cada palabra es proporcional a su frecuencia de aparición, destacando así las más recurrentes.

Para la generación de estas visualizaciones, se tienen en cuenta las siguientes consideraciones:

- Se eliminan palabras frecuentes del idioma inglés (por ejemplo, “and”, “the”, “is” o “a”) que no aportan información relevante sobre el contenido temático de los artículos, a estas palabras las llamamos *stopwords*. Esta consideración permite destacar términos con mayor valor semántico.
- Se decide restringir la cantidad de términos mostrados para mantener la claridad visual y facilitar la interpretación de las nubes de palabras. Pero el mismo análisis se podría realizar con una mayor cantidad de palabras.



Figura 2: Palabras más frecuentes en los artículos de Reuters




Figura 3: Palabras más frecuentes en los artículos de The New York Times




Figura 4: Palabras más frecuentes en los artículos de CNBC




Figura 5: Palabras más frecuentes en los artículos de The Hill




Figura 6: Palabras más frecuentes en los artículos de People

Observando las nubes de palabras, el término 'said' se encuentra muy presente en todos los medios y consideramos que no aporta información que ayude a identificar de que medio proviene un artículo. Este tipo de palabras podría incorporarse a la lista de *stopwords* para mejorar la discriminación entre medios.

También se puede observar que hay palabras que sí parecen ser características del medio. Por ejemplo, "trump" aparece con alta frecuencia en **The Hill**, "china" en **Reuters** y "market" en **CNBC**. Estas palabras sí podrían ayudar a identificar al medio.

Como posible extensión de esta visualización, podrían generarse nubes de palabras separadas por sección temática (por ejemplo, política, economía o deportes), por período temporal o por tipo de noticia. Esto permitiría analizar cómo cambian los términos más frecuentes según el contexto y facilitaría la comparación entre distintas categorías de artículos.

B. Medios con mayor cantidad de palabras

Al contar la cantidad total de palabras por medio se obtiene la Tabla 3, que presenta en orden descendente los medios con mayor volumen de palabras publicadas.

Sin embargo, el conteo de palabras puede verse afectado por distintos factores, entre ellos:

- El uso de contracciones propias del idioma inglés, como "don't", que podrían contabilizarse como una única palabra cuando en realidad son dos.
- El uso de abreviaciones, como "U.S.A.", que podrían considerarse como una sola palabra cuando en realidad representan múltiples términos.
- El uso de plantillas o fragmentos repetitivos que no aportan contenido semántico relevante. Por ejemplo, **Reuters** frecuentemente incluye en el

cuerpo de sus artículos el lugar de la noticia seguido por la expresión “(Reuters)”, como en “WASHINGTON (Reuters)”.

- La existencia de artículos repetidos dentro de un mismo medio. Esto puede incrementar artificialmente la cantidad total de palabras asociadas a dicho medio.

Como posible mitigación de estos problemas se podrían realizar las siguientes consideraciones:

- Expandir las contracciones y abreviaciones a sus formas completas y eliminar las plantillas repetitivas identificadas en los artículos de los distintos medios. En los resultados presentados en la tabla 3, la expansión de contracciones ya fue considerada.
- Eliminar artículos repetidos pertenecientes a un mismo medio antes de realizar el conteo.

Además, este método de conteo no contempla la cantidad de artículos publicados por cada medio. Como consecuencia, medios con un gran volumen de publicaciones, como **Reuters**, tienden a ocupar los primeros lugares de la tabla.

Si el objetivo fuera identificar qué medios escriben artículos más extensos, este enfoque podría conducir a conclusiones incorrectas. Una posible mejora consiste en calcular la cantidad promedio de palabras por artículo para cada medio, permitiendo comparar la longitud promedio de las publicaciones de manera más representativa.

C. Matriz de menciones entre medios

Para representar esta matriz se utiliza un mapa de calor, en el cual los colores más saturados indican valores de mayor magnitud. La Figura 7 muestra la matriz de menciones entre medios.

Como es esperable, las entradas de la diagonal principal presentan los valores más altos, ya que representan la cantidad de veces que un medio se menciona a sí mismo. En particular, **Reuters** exhibe un valor especialmente elevado de automenciones. Esto se puede deber al uso frecuente de plantillas que incluyen su nombre en los artículos, sumado a la gran cantidad de publicaciones que posee en comparación con los demás medios.

También puede observarse que **Reuters** es el medio más mencionado por otros medios, excluyendo las automenciones, con un total de 1384 referencias. Mientras, **CNBC** es el medio menos mencionado, con un total de 72 menciones.

Otro aspecto interesante es que **Reuters** es mencionado 1200 veces en artículos de **CNBC**, un valor considerablemente alto para referencias entre medios distintos.

Tabla 3: Cantidad total de palabras por medio.

Medio	Total Palabras
The New York Times	2583676
Reuters	2548200
The Hill	1350918
CNBC	1214234
CNN	971201
Vice	928817
People	631751
Vox	601012
Refinery 29	463129
Mashable	445251
Business Insider	362249
Politico	362177
The Verge	345982
TechCrunch	304058
Buzzfeed News	303057
Economist	207083
Gizmodo	179139
Vice News	155815
Fox News	152057
Axios	121841
New Republic	116243
Hyperallergic	99868
Wired	98621
TMZ	93739
New Yorker	93498
Washington Post	26180

D. Preguntas propuestas

Algunas preguntas interesantes que podrían intentar responderse a partir de la matriz de menciones son las siguientes:

■ ¿Qué medio se automenciona con mayor frecuencia?

Para responder esta pregunta, pueden tomarse los valores de la diagonal principal de la matriz, ya que representan las automenciones de cada medio. Luego, estos valores deberían normalizarse por la cantidad total de artículos publicados por el medio correspondiente. Una vez realizada esta normalización, basta con identificar cuál de las entradas obtiene el valor máximo. Es importante destacar que si no se realiza la normalización por la cantidad de artículos, los medios más populares podrían fácilmente figurar como los más autoreferenciados.




Figura 7: Matriz de menciones entre medios

■ **¿Qué medios funcionan como fuentes de referencia para otros?**

Esta pregunta puede abordarse analizando qué medios reciben la mayor cantidad de menciones provenientes de otros medios, excluyendo las automenciones. Para ello, puede sumarse cada columna de la matriz sin considerar la entrada diagonal correspondiente. Los medios cuyos valores resulten más altos pueden interpretarse como fuentes de referencia. Reuters constituye un ejemplo típico, ya que numerosos medios reutilizan o citan su contenido.

■ **¿La cantidad de menciones se correlaciona con el tamaño o volumen de publicación del medio?**

Puede investigarse si los medios que publican una mayor cantidad de artículos también tienden a recibir más menciones, o si algunos medios destacan independientemente de su volumen de publicación. Para ello, sería posible comparar la cantidad total de artículos de cada medio con la cantidad de menciones recibidas en la matriz.

Referencias

- [1] Trump Impeachment timeline, <https://www.theguardian.com/us-news/2019/oct/31/trump-impeachment-inquiry-timeline-key-events>
- [2] Covid timeline, <https://www.cdc.gov/museum/timeline/covid19.html>