



UNIVERSIDAD DE LA REPÚBLICA
FACULTAD DE INGENIERÍA



Maestría en Ciencia de Datos y Aprendizaje Automático
Introducción a la Ciencia de Datos

Tarea 2

Mateo Trujillo 5196121-1
Nicole Cabot 4678001-2

1. Dataset y representación numérica de texto

A. Preparación del dataset

Inicialmente se seleccionaron los tres medios de prensa con mayor cantidad de artículos presentes en el dataset. Para ello se contabilizó la cantidad de noticias por medio utilizando la función `value_counts()` de Pandas y se conservaron únicamente los tres más frecuentes. Los medios obtenidos fueron Reuters, The New York Times y CNBC. La Figura 1 muestra la cantidad de artículos correspondientes a cada uno de los medios seleccionados. Se observa que Reuters constituye la fuente con mayor cantidad de noticias, con 9431 artículos, mientras que The New York Times y CNBC presentan 2840 y 2623 artículos respectivamente.




Figura 1: Cantidad de artículos por medio de prensa en el subconjunto de datos utilizado.

Posteriormente se aplicó la función de preprocesamiento `clean_text()` sobre el contenido de cada artículo. Esta función realizó las siguientes transformaciones:

- Eliminación de la primera línea del texto, es decir, todo el contenido anterior al primer salto de línea.
- Conversión de todos los caracteres a minúsculas.
- Normalización de contracciones frecuentes en inglés (por ejemplo, *can't* → *cannot*, *don't* → *do not*, *it's* → *it is*).
- Eliminación de signos de puntuación, números y caracteres especiales mediante su reemplazo por espacios.
- Eliminación de saltos de línea para obtener texto continuo.

Estas operaciones tienen como objetivo reducir la variabilidad del vocabulario y facilitar la posterior representación numérica de los documentos.

Una vez completada la limpieza, el conjunto de datos se dividió en un conjunto de entrenamiento (70 %) y un conjunto de prueba (30 %) utilizando la función `train_test_split` de Scikit-learn.

La partición se realizó mediante muestreo estratificado utilizando el parámetro `stratify`, asegurando que la proporción de artículos pertenecientes a cada medio de prensa se mantuviera tanto en el conjunto de entrenamiento como en el conjunto de prueba. Además, se fijó el parámetro `random_state = 42` para garantizar la reproducibilidad de los resultados.

El procedimiento utilizado fue el siguiente:

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.30,
    stratify=y,
    random_state=42
)
```

B. Verificación del balance de clases

Para verificar que la partición de los datos conservó la proporción de artículos de cada medio de prensa, se realizó una visualización comparando la cantidad de artículos presentes en los conjuntos de entrenamiento y prueba para cada clase.

La Figura 2 muestra la distribución de artículos por medio de prensa en ambos conjuntos. Se observa que las proporciones entre Reuters, The New York Times y CNBC se mantienen de forma consistente luego de la partición, evidenciando que el muestreo estratificado preservó adecuadamente la distribución original de las clases.




Figura 2: Distribución de artículos por medio de prensa en los conjuntos de entrenamiento y prueba.

Los valores obtenidos para cada conjunto fueron los siguientes:

Medio	Train	Test
Reuters	6601	2830
The New York Times	1988	852
CNBC	1836	787

Tabla 1: Cantidad de artículos por medio de prensa en los conjuntos de entrenamiento y prueba.

La relación de 70 % para entrenamiento y 30 % para prueba se mantiene para las tres clases, confirmando que la partición estratificada se realizó correctamente.

C. Representación Bag of Words

Bag of Words (BoW) es una técnica de Procesamiento de Lenguaje Natural (NLP) para el tratamiento de documentos, especialmente su clasificación. Extrae cada palabra única del documento y contabiliza la frecuencia en la que aparece. No toma en cuenta el orden y la gramática, únicamente su frecuencia.

Es habitual realizar un preprocesamiento previo a la construcción de la representación *Bag of Words*. Dicho preprocesamiento suele incluir la conversión de todo el texto a minúsculas, la eliminación de signos de puntuación y, en algunos casos, la eliminación de palabras vacías (*stop words*). De esta manera, se evita considerar una misma palabra como términos diferentes debido únicamente a variaciones en el uso de mayúsculas o a la presencia de caracteres no relevantes.

Ejemplo:

- Documento 1: *Machine learning models learn from data*
- Documento 2: *Data science uses data to build models*

El preprocesamiento para el documento 1 se puede ver en los siguientes pasos:

- **Conversión a minúsculas:**
 - Original: *Machine Learning Models Learn From Data*
 - Procesado: *machine learning models learn from data*
- **Tokenización:** separación del texto en palabras individuales.
 - Texto: *machine learning models learn from data*
 - Tokens: {machine, learning, models, learn, from, data}
- **Eliminación de palabras vacías (*stop words*):**
 - Antes: *machine learning models learn from data*
 - Después: *machine learning models learn data*

En este caso, la palabra *from* se elimina por considerarse una palabra de alta frecuencia y bajo contenido semántico.

- **Lematización:** reducción de las palabras a su forma base.
 - Antes: *machine learning models learn from data*
 - Después: *machine learning model learn from data*
- **Stemming:** reducción de las palabras a una raíz común.
 - Antes: *machine learning models learn data*
 - Después: *machine learn model learn data*

Al concluir este preprocesamiento (sin incluir la lematización ni el *stemming*), el vocabulario generado es:

{build, data, learn, learning, machine, models, science, uses}

La representación *Bag of Words* de ambos documentos es:

Documento	build	data	learn	learning	machine	models	science	uses
Documento 1	0	1	1	1	1	1	0	0
Documento 2	1	2	0	0	0	1	1	1

Tabla 2: Representación Bag of Words

Si el conjunto de datos contiene N documentos y el vocabulario posee V palabras únicas, la matriz resultante tiene dimensiones:

$$N \times V$$

En este ejemplo, la matriz tiene tamaño:

$$2 \times 8$$

ya que existen dos documentos y ocho términos únicos.

La matriz de *BoW* suele contener una gran cantidad de ceros, ya que cada documento utiliza únicamente una pequeña fracción del vocabulario total, ocupando mucha memoria RAM. Por esta razón, se emplean *sparse matrices* (matrices dispersas), las cuales almacenan únicamente los valores distintos de cero junto con sus posiciones. Esto reduce significativamente el consumo de memoria y permite trabajar eficientemente con conjuntos de datos de alta dimensionalidad.

Para esta sección de la tarea se utilizó *CountVectorizer* para transformar los documentos de texto en una matriz *Bag of Words*. La matriz resultante tiene una dimensión de (10425, 78284). El número de filas corresponde al de artículos de nuestro espacio de entrenamiento. Mientras que la cantidad de columnas representa la cantidad de términos únicos, para esta tarea se obtuvieron 78284 términos únicos.

D. Representación TF-IDF

Un *n*-grama es una secuencia de *n* palabras consecutivas dentro de un texto. Por ejemplo, para la oración *Data science uses data to build models*:

- Unigramas ($n = 1$): Data, science, uses, data, to, build, models.
- Trigramas ($n = 3$): Data science uses, science uses data, uses data to, data to build, to build models.

Los *n*-gramas permiten conservar parte de la información secuencial que se pierde en *BoW*.

TF-IDF es una representación numérica que mide la importancia de una palabra en un documento, considerando dos aspectos: su frecuencia dentro del documento (TF) y su poca aparición en el conjunto total de documentos (IDF). Se utiliza para destacar las palabras más relevantes de un documento para su clasificación.

En términos matemáticos:

TF (Term Frequency): mide cuántas veces aparece un término t en un documento d .

$$TF(t, d) = \frac{\text{número de veces que aparece } t \text{ en } d}{\text{total de palabras en } d}$$

IDF (Inverse Document Frequency): mide qué tan raro o común es un término t en todo el corpus.

$$IDF(t) = \log \left(\frac{N}{DF(t)} \right)$$

donde:

- N : número total de documentos
- $DF(t)$: número de documentos que contienen el término t

TF-IDF (transformación final) se obtiene multiplicando ambos valores:

$$TF-IDF(t, d) = TF(t, d) \cdot IDF(t)$$

Para esta tarea se empleó la función *TfidfVectorizer* para convertir los documentos preprocesados en una matriz término-documento ponderada mediante TF-IDF. Se eliminaron las stop words en inglés y se consideraron únicamente unigramas. Los pesos obtenidos reflejan la importancia relativa de cada término en un documento respecto del corpus completo.

A modo de comprobar la implementación se obtiene la Tabla 3, esta muestra los 20 términos con mayor peso TF-IDF para el documento 0. Se observa que términos como *container*, *maersk* y *hapag* presentan los valores más elevados, indicando que son altamente representativos del contenido de dicho documento respecto al resto del corpus.

Tabla 3: Mayores 20 valores TF-IDF para el documento 0

Término	TF-IDF
container	0.4121
maersk	0.3812
hapag	0.2714
investigation	0.2622
msc	0.2402
doj	0.2107
shipping	0.2082
lloyd	0.1902
moller	0.1810
finer	0.1166
antitrust	0.1139
industry	0.0968
practices	0.0943
holtse	0.0905
companies	0.0849
global	0.0834
tuesday	0.0784
bananas	0.0774
eckert	0.0774
closed	0.0772

E. Visualización PCA sobre TF-IDF

E.1. Variación de PCA modificando parámetros

Se obtienen las siguientes visualizaciones:

- La Figura 3 que muestra PCA sobre TF-IDF con useidf False, sin eliminar stop words y ngram range (1,1)
- La Figura 4 que muestra PCA sobre TF-IDF con useidf True, sin eliminar stop words y ngram range (1,1)
- La Figura 5 que muestra PCA sobre TF-IDF con useidf False, eliminando stop words y ngram range (1,1)
- La Figura ?? que muestra PCA sobre TF-IDF con useidf False, sin eliminar stop words y ngram range (1,2)

En la figura 3, se observa que las dos primeras componentes permiten capturar parte de la estructura de los datos, aunque la separación entre los distintos medios de prensa no es completamente clara. Existen regiones donde documentos de diferentes publicaciones se superponen. Además se hace evidente el hecho de las republicaciones de las noticias de Reuters de parte de CNBC.

Al eliminar las stop words del idioma inglés, se redujo la influencia de palabras muy frecuentes y poco informativas. Esto permitió que términos con mayor contenido semántico tuvieran un peso relativamente mayor en la representación vectorial. Como resultado, los grupos observados en PCA en la figura 3 tendieron a diferenciarse entre ellos ya que la nube de puntos se expandió.

La incorporación del factor IDF penaliza las palabras que aparecen en una gran cantidad de documentos y resalta aquellas más distintivas. Esto suele generar representaciones más discriminativas, ya que palabras características de ciertos temas o estilos editoriales adquieren mayor relevancia. En consecuencia, se observó una mejor diferenciación entre algunos grupos de documentos respecto a la representación basada únicamente en frecuencias de términos. Un ejemplo de esto se puede observar en la figura 4, los artículos de The New York Times se pueden distinguir de los otros medios con facilidad. Lo anterior no sucede al no usar el factor IDF como se puede apreciar en la figura 3.

La inclusión de bigramas permite capturar expresiones compuestas y patrones del lenguaje que no pueden representarse mediante unigramas aislados. Esto agrega información del contexto y puede ayudar a distinguir estilos editoriales específicos. Sin embargo, también incrementa considerablemente la dimensionalidad del espacio de características, por lo que la mejora en la separación visual no siempre es significativa cuando se proyecta únicamente




Figura 3: PCA sobre TF-IDF con useidf False, sin eliminar stop words y ngram range (1,1)




Figura 4: PCA sobre TF-IDF con useidf True, sin eliminar stop words y ngram range (1,1)




Figura 5: PCA sobre TF-IDF con useidf False, eliminando stop words del ingles y ngram range (1,1)



Figura 6: PCA sobre TF-IDF con useidf False, sin eliminar stop words y ngram range (1,2)

sobre dos componentes principales.

Los resultados sugieren que no es posible separar completamente los medios de prensa utilizando únicamente dos componentes principales. Aunque pueden observarse ciertas tendencias de agrupamiento, existe una superposición considerable entre clases.

Esta superposición se debe a la republicación de varios artículos de Reuters por parte de CNBC y la similitud en los temas abordados por Reuters Y the New York Times.

Además, es necesario tomar en cuenta que la información original se encuentra en un espacio de muy alta dimensionalidad y la proyección a dos dimensiones implica una pérdida importante de información. Por este motivo, es necesario analizar la varianza explicada acumulada para determinar cuántas componentes son necesarias para representar adecuadamente los datos.

E.2. Evolución de la varianza con el agregado de componentes

Se obtiene la curva de varianza de la figura 7 que muestra que las dos primeras componentes capturan únicamente una pequeña fracción de la varianza total (menos del 20%), entonces resulta esperable que la separación visual sea limitada.

Al incorporar más componentes principales, la representación conserva una mayor cantidad de información relevante. Esto tiene sentido pues la representación en PCA considera las componentes de los datos que presentan mayor varianza (aunque reduciendo la información de los datos).




Figura 7: evolución varianza en representación PCA al agregar componentes

E.3. Separación de medios observada

La separación observada entre algunos grupos de documentos puede atribuirse a una combinación de diferencias temáticas, diferencias de estilo editorial y la presencia de pistas explícitas del medio que no fueron completamente eliminadas durante la etapa de limpieza.

- Diferencias temáticas: Reuters tiene una fuerte presencia de noticias financieras y económicas, mientras que The New York Times presenta una mayor variedad de contenidos políticos, culturales y sociales. Estas diferencias temáticas generan vocabularios característicos que influyen en la representación TF-IDF.
- Diferencias de estilo editorial: Cada medio utiliza expresiones, estructuras gramaticales y formas de redactar particulares, lo que puede reflejarse en la frecuencia de ciertos términos o combinaciones de palabras. La inclusión de bigramas permite capturar parte de estas diferencias estilísticas.
- Pistas explícitas: Aunque se aplicaron procedimientos de limpieza, es posible que permanezcan referencias a agencias de noticias, nombres de periodistas, secciones específicas o fórmulas editoriales recurrentes. Esto resulta especialmente evidente en el caso de CNBC, que republica muchos artículos de Reuters, lo que explica la fuerte superposición observada entre ambos conjuntos de documentos.

En consecuencia, la separación obtenida mediante PCA se interpreta como el resultado de la combinación de contenido, estilo editorial y posibles indicadores explícitos de la fuente original.

2. Entrenamiento y Evaluación de Modelos

A. Multinomial Naive Bayes

Para resolver el problema de clasificación de artículos según el medio de prensa al que pertenecen se utilizó el clasificador *Multinomial Naive Bayes*. Este clasificador utiliza un modelo probabilístico basado en el teorema de Bayes. Su objetivo es calcular la probabilidad de que un artículo pertenezca a cada uno de los medios considerados y asignarlo a aquel cuya probabilidad sea mayor. Matemáticamente, el modelo calcula:

$$P(y | x) = \frac{P(x | y) P(y)}{P(x)}$$

donde:

- x representa el artículo de prensa,
- y representa el medio de prensa (Reuters, CNBC, The New York Times, etc.),
- $P(y)$ es la probabilidad a priori de cada medio,
- $P(x | y)$ es la probabilidad de observar el artículo suponiendo que pertenece al medio y .

Calcular directamente $P(x|y)$ resulta muy costoso, ya que un artículo puede contener cientos o miles de palabras. Para simplificar este cálculo, Naive Bayes supone que, conocido el medio de prensa, la aparición de cada palabra es independiente de las demás. Gracias a esta hipótesis, la probabilidad del artículo puede aproximarse mediante el producto de las probabilidades de sus palabras:

$$P(x|y) \approx \prod_{i=1}^d P(x_i|y)$$

Donde x_i representa la presencia o frecuencia de la palabra i en el artículo.

Durante el entrenamiento, el modelo estima estas probabilidades $P(x_i|y)$ utilizando la frecuencia con la que aparece cada palabra en los artículos de cada medio. Por ejemplo, si la palabra *market* aparece con mucha frecuencia en artículos de Reuters y con menor frecuencia en los demás medios, el modelo asignará un valor alto a $P(\text{market}|\text{Reuters})$ y valores menores para las restantes clases.

Para ilustrar el funcionamiento del modelo, supongamos que un artículo contiene principalmente palabras como *market*, *stock* e *investor*. Durante la clasificación, el modelo calcula la probabilidad de observar estas palabras para cada uno de los medios (Reuters, CNBC y The New York Times). Si el producto de probabilidades resulta mayor para Reuters, entonces el artículo será clasificado como perteneciente a Reuters.

La matriz TF-IDF obtenida en los pasos anteriores se utilizó como entrada para entrenar un clasificador Multinomial Naive Bayes.

Un modelo bueno corresponde con una matriz con mayores valores en la diagonal (la clasificación predicha concuerda con la real). En este caso esto no sucede, la línea principal corresponde a la predicción de Reuters. Dicho resultado concuerda con el desbalance en el número de artículos; Reuters publica muchos más artículos que el resto y, por lo tanto, el modelo aprende mejor su distribución y puede asociar ese medio a casos ambiguos.

El valor de accuracy obtenido es: 0.7216.

La definición de dicho termino es:

$$\text{Accuracy} = \frac{\text{Predicciones correctas}}{\text{Total de predicciones}}$$

Esto significa que el 72 % de los artículos fueron clasificados correctamente. Esto se corresponde con lo observado en la matriz de la figura 8.




Figura 8: Matriz de confusión

Por otro lado, se calculan los valores de precision y recall obteniendo así la tabla 4.

Tabla 4: Precisión y recall obtenidos con el clasificador Multinomial Naive Bayes

Medio	Precisión	Recall
CNBC	1.00	0.02
Reuters	0.70	1.00
The New York Times	0.95	0.46

La precisión determina cuantos articulos que fueron clasificados en cierta categoria realmente pertenecen a ella:

$$\text{Precisión} = \frac{TP}{TP + FP}$$

donde TP indica True Positives (positivos verdaderos) y FP indica False Positives (falsos positivos).

El recall indica cuantos artículos pertenecientes a una categoría fueron realmente clasificados como tal, y su fórmula es:

$$\text{Recall} = \frac{TP}{TP + FN}$$

donde TP indica True Positives (positivos verdaderos) y FN indica False Positives (falsos negativos).

A partir de la tabla 4 se determina:

- CNBC: Cuando el modelo predice que un artículo es de CNBC, siempre acierta (alta precision). Sin embargo, identifica únicamente el 2 % de todos los artículos de CNBC (bajo recall).

- Reuters: El modelo identifica prácticamente todos los artículos de Reuters, pero aproximadamente El 30 % de los artículos que clasifica como tal pertenecen en realidad a otro medio (precisión moderada) e identifica prácticamente todos los artículos de ese medio (alto recall).
- The New York Times: Cuando el modelo predice que un artículo es the The New York times casi siempre acierta (alta precisión) pero sin embargo identifica únicamente al 46 % de los artículos pertenecientes a dicho medio.

Problema del uso de accuracy: Accuracy provee el porcentaje de artículos que fueron clasificados correctamente. En el caso de una base de datos muy dispar, la accuracy no sería un valor fiable para indicar un buen modelo. Un modelo puede obtener una alta accuracy simplemente prediciendo la clase mayoritaria para todos los artículos. Si Reuters ocupase el 98 % del total de artículos, clasificando todos los ellos como provenientes de dicho medio, obtendríamos un accuracy muy alto de 98 %.

B. Validación cruzada y búsqueda de hiperparámetros

Un ajuste más que podemos realizar a nuestro modelo es la selección de hiperparámetros. Los hiperparámetros son configuraciones del modelo que no se aprenden directamente a partir de los datos, sino que deben definirse antes del entrenamiento. Estos parámetros controlan el comportamiento del algoritmo y tienen un impacto directo en su desempeño.

En el caso del modelo de *Naive Bayes*, uno de los hiperparámetros más importantes es α , utilizado para el suavizado de Laplace (*Laplace smoothing*). Este suavizado evita asignar probabilidades nulas a características que no aparecen en el conjunto de entrenamiento. En el caso del *Multinomial Naive Bayes*, este parámetro se incorpora en el cálculo de las probabilidades condicionales de la forma:

$$P(x_i | y) = \frac{N_{y,i} + \alpha}{N_y + \alpha \cdot d}$$

donde:

- $N_{y,i}$ representa la cantidad de veces que la característica i aparece en la clase y ,
- N_y es el total de ocurrencias de todas las características en la clase y ,
- d es el número total de características,
- α es el parámetro de suavizado.

El uso de α evita asignar probabilidades nulas a palabras que no fueron observadas para una determinada clase durante el entrenamiento, mejorando la estabilidad del modelo frente a datos escasos o poco frecuentes.

Para evaluar el desempeño del modelo de manera más robusta y hallar el valor de α que mejor se ajusta a nuestros datos se utiliza la *validación cruzada* (*cross-validation*), específicamente el esquema de k -fold. En este procedimiento, el conjunto de entrenamiento se divide en k subconjuntos o *folds*. El modelo se entrena k veces: en cada iteración se utilizan $k - 1$ folds para entrenamiento y el fold restante para validación.

Para un valor fijo de α , el modelo se ajusta en cada partición y se calcula una métrica de desempeño (por ejemplo, *accuracy*). Luego, se obtiene el promedio de dichas métricas, lo que permite estimar el rendimiento del modelo de forma más estable y menos dependiente de una única partición de los datos. En la figura 9 se muestra esquemáticamente el proceso de validación cruzada para $k = 5$ folds. Este proceso se repite para distintos valores de α y se selecciona el α que obtiene las mejores métricas.

Para implementar este proceso de forma sistemática se utilizó la función `GridSearchCV` de *scikit-learn*, esta permite realizar búsqueda exhaustiva de hiperparámetros combinada con validación cruzada. Esta función recibe los siguientes parámetros principales:

- **estimator**: el modelo a entrenar (Multinomial Naive Bayes),
- **param_grid**: conjunto de valores de α a evaluar,
- **cv**: número de folds utilizados en la validación cruzada,
- **scoring**: métrica de evaluación utilizada (*accuracy*).




Figura 9: Esquema de validación cruzada tipo k -fold

Para este trabajo se evaluaron los valores $\alpha = [0,01, 0,1, 0,5, 1,0, 5,0, 10,0]$, utilizando validación cruzada con $k = 5$ folds y la métrica *accuracy* para medir el desempeño del modelo. Para cada valor de α , GridSearchCV ejecuta validación cruzada completa y calcula el promedio del *accuracy* en todos los folds. Finalmente, se selecciona el valor de α que obtiene el mejor rendimiento promedio con la métrica *accuracy*.

El mejor resultado obtenido fue $\alpha = 0,1$, con un *accuracy* promedio de 0,8143 en validación cruzada.

Finalmente, para analizar el comportamiento del modelo en cada partición, se generó el gráfico de violín de la figura 10 que muestra la distribución del *accuracy* obtenido en cada fold para cada valor de α . Cada violín representa la distribución de los valores de *accuracy* obtenidos durante la validación cruzada para un valor particular de α . El ancho del violín indica la densidad de observaciones para cada valor de la métrica: cuanto más ancho es el gráfico en una determinada región, mayor es la cantidad de folds que obtuvieron valores de *accuracy* cercanos a dicha región.

Además, el punto blanco indica la mediana del *accuracy*, mientras que la cruz roja representa el valor promedio. Puede observarse que los valores $\alpha = 0,1$ y $\alpha = 0,01$ presentan los mejores desempeños, ya que sus medias y medianas son las más elevadas. Por otro lado, valores mayores de α producen una disminución significativa del desempeño, con medias y medianas inferiores a 0,75.




Figura 10: Gráfico de Violín para los distintos alfas

C. Entrenamiento final con el mejor modelo

Una vez seleccionado el mejor hiperparámetro mediante validación cruzada ($\alpha = 0,1$), se volvió a entrenar el modelo utilizando la totalidad del conjunto de entrenamiento disponible. De esta manera, el modelo final puede aprovechar toda la información disponible para estimar sus parámetros.

En la Tabla 5 se presentan las métricas obtenidas sobre el conjunto de prueba. El modelo alcanzó un *accuracy* de 0.81, mostrando un buen desempeño general en la tarea de clasificación. Sin embargo, se observan diferencias importantes entre las distintas clases. Reuters presenta el mayor recall (0.94), mientras que CNBC obtiene un recall considerablemente menor (0.34), indicando que una proporción importante de sus artículos es clasificada incorrectamente.

Tabla 5: Métricas obtenidas por el modelo final sobre el conjunto de prueba

Clase	Precision	Recall
CNBC	0.84	0.34
Reuters	0.82	0.94
The New York Times	0.76	0.80
Accuracy = 0.81		

La selección del hiperparámetro mediante validación cruzada permitió mejorar significativamente el desempeño del modelo respecto a la configuración inicial. Antes del ajuste, el clasificador tendía a favorecer fuertemente la clase Reuters, obteniendo un recall de 1.00 para dicha clase, pero un recall extremadamente bajo para CNBC (0.02) y moderado para The New York Times (0.46). Luego de seleccionar el valor óptimo de α , las métricas se vuelven considerablemente más equilibradas entre las distintas clases. En particular, el recall de CNBC aumenta de 0.02 a 0.34 y el de The New York Times de 0.46 a 0.80. Si bien Reuters experimenta una leve disminución en recall (de 1.00 a 0.94), también mejora su precisión (de 0.70 a 0.82). Esto indica que el modelo ajustado logra una mejor capacidad de generalización y reduce la tendencia a clasificar excesivamente los documentos como Reuters.




Figura 11: Matriz de confusión obtenida por el modelo final sobre el conjunto de prueba.

La matriz de confusión mostrada en la Figura 11 permite analizar con mayor detalle los errores cometidos por el modelo. Se observa que una gran cantidad de artículos pertenecientes a CNBC son clasificados como Reuters, lo que explica el bajo valor de recall obtenido para la clase CNBC (0.34). Sin embargo, la precisión para esta clase es elevada (0.84), indicando que cuando el modelo predice CNBC suele hacerlo correctamente.

Una posible explicación para esta confusión entre clases es que CNBC suele republicar o basarse en artículos originalmente producidos por Reuters, por lo que ambos medios comparten gran parte de su vocabulario.

Por otro lado, los artículos de The New York Times presentan un comportamiento más equilibrado, con valores relativamente altos tanto de precisión como de recall, lo que indica que el modelo logra identificar características distintivas de este medio con mayor facilidad.

La confusión observada entre CNBC y Reuters ilustra una limitación importante de los modelos basados en Bag of Words o TF-IDF. Estas representaciones describen los documentos únicamente mediante la frecuencia de aparición de palabras, ignorando el orden, el contexto y las relaciones semánticas entre ellas. Como consecuencia, dos textos con significados diferentes pero vocabulario similar pueden resultar difíciles de distinguir. Asimismo, estos enfoques no capturan sinónimos, ironías, dependencias sintácticas ni información contextual más compleja.

D. Modelo alternativo

Además de Multinomial Naive Bayes, se evaluó un modelo de Regresión Logística utilizando las mismas características de texto.

En este problema, cada artículo es representado mediante un vector TF-IDF, donde cada componente indica la importancia de una palabra del vocabulario dentro del documento. La Regresión Logística utiliza estos vectores para aprender qué palabras son más características de cada medio de prensa. Durante la clasificación, el modelo calcula una puntuación para cada clase combinando los valores TF-IDF del documento con los parámetros aprendidos durante el entrenamiento y asigna el artículo a la clase con mayor probabilidad.

A diferencia de Multinomial Naive Bayes, que modela las probabilidades de aparición de las palabras dentro de cada clase asumiendo independencia entre ellas. La Regresión Logística aprende directamente una frontera de decisión que separa las distintas clases a partir de los vectores TF-IDF. Esto le permite aprovechar mejor la información contenida en los documentos y, en muchos casos, obtener un mejor desempeño en tareas de clasificación de texto.

Las métricas obtenidas sobre el conjunto de prueba se muestran en la Tabla 6.

Tabla 6: Métricas obtenidas por el modelo de Regresión Logística

Clase	Precision	Recall
CNBC	0.89	0.47
Reuters	0.84	0.98
The New York Times	0.94	0.82
Accuracy = 0.86		

La matriz de confusión correspondiente se muestra en la Figura 12.

Al comparar estos resultados con los obtenidos mediante Multinomial Naive Bayes, se observa una mejora general en el desempeño del modelo. El accuracy aumenta de 0.81 a 0.86, lo que representa una mejora de aproximadamente cinco puntos porcentuales.

Analizando las métricas por clase, la mejora más significativa se observa en CNBC, cuyo recall aumenta de 0.34 a 0.47, indicando que el modelo logra identificar una mayor proporción de artículos pertenecientes a esta clase. Reuters también mejora su recall, pasando de 0.94 a 0.98, mientras que The New York Times presenta incrementos tanto en precisión como en recall.

La matriz de confusión muestra que sigue existiendo cierta confusión entre CNBC y Reuters, aunque en menor medida que en el modelo de Naive Bayes. Esto sugiere que la similitud del vocabulario entre ambos medios continúa siendo un desafío para la clasificación. Sin embargo, la Regresión Logística logra una mejor separación entre las clases al no asumir independencia entre las características.

En conclusión, utilizando exactamente las mismas características de texto, la Regresión Logística obtuvo mejores resultados que Multinomial Naive Bayes tanto en accuracy como en las métricas por clase, por lo que constituye el mejor modelo evaluado para esta tarea de clasificación de noticias.

E. Cambio de medio de prensa

Con el objetivo de analizar cómo influye la elección de los medios de prensa en la tarea de clasificación, se realizaron experimentos adicionales reemplazando uno de los medios utilizados originalmente. El modelo empleado fue nuevamente Multinomial Naive Bayes utilizando las mismas características de texto.




Figura 12: Matriz de confusión obtenida con Regresión Logística.

En un primer experimento se sustituyó CNBC por *The Hill*, manteniendo Reuters y The New York Times. Las métricas obtenidas se muestran en la Tabla 7.

Tabla 7: Métricas obtenidas utilizando Reuters, The Hill y The New York Times

Clase	Precision	Recall
Reuters	0.94	0.95
The Hill	0.87	0.93
The New York Times	0.87	0.78
Accuracy = 0.91		

La matriz de confusión correspondiente se muestra en la Figura 13. Se observa una reducción significativa de los errores de clasificación respecto al experimento original, obteniéndose un accuracy de 0.91, considerablemente superior al 0.81 alcanzado cuando se utilizaban Reuters, CNBC y The New York Times.

En un segundo experimento se sustituyó Reuters por *The Hill*, manteniendo CNBC y The New York Times. Los resultados obtenidos se presentan en la Tabla 8.

Tabla 8: Métricas obtenidas utilizando CNBC, The Hill y The New York Times

Clase	Precision	Recall
CNBC	0.89	0.81
The Hill	0.84	0.96
The New York Times	0.89	0.86
Accuracy = 0.88		

La matriz de confusión asociada se muestra en la Figura 14. Nuevamente se observa una disminución importante de las confusiones entre clases respecto al experimento original, alcanzándose un accuracy de 0.88.

Estos resultados sugieren que la principal dificultad observada inicialmente no estaba asociada únicamente al clasificador utilizado, sino a la similitud existente entre Reuters y CNBC. Como se observó anteriormente en la matriz de confusión del experimento original, una gran cantidad de artículos de CNBC eran clasificados como Reuters. Una posible explicación es que CNBC suele republicar o basarse en artículos originalmente producidos por Reuters,

por lo que ambos medios comparten gran parte de su vocabulario. Dado que el modelo utiliza representaciones Bag of Words o TF-IDF, documentos con distribuciones de palabras similares resultan difíciles de distinguir.

También es importante analizar el desbalance presente en los datos. Reuters cuenta con aproximadamente 9431 artículos, mientras que The New York Times posee 2840, CNBC 2623 y The Hill 2349. Por lo tanto, Reuters dispone de una cantidad considerablemente mayor de ejemplos que las demás clases.

En problemas de clasificación, este tipo de desbalance puede provocar que el modelo favorezca sistemáticamente a la clase mayoritaria, reduciendo el recall de las clases minoritarias. Sin embargo, los resultados obtenidos sugieren que el desbalance no constituye el principal factor que limita el desempeño del modelo. Si bien Reuters es la clase más numerosa, la mejora observada al reemplazar CNBC o Reuters por The Hill indica que la similitud léxica entre Reuters y CNBC tiene un impacto más importante que la diferencia en cantidad de ejemplos.

En escenarios con desbalances más severos podrían emplearse técnicas de sobre-muestreo (*oversampling*) para aumentar artificialmente la cantidad de ejemplos de las clases minoritarias o técnicas de submuestreo (*undersampling*) para reducir la cantidad de ejemplos de las clases mayoritarias. No obstante, dado que las métricas obtenidas son elevadas y relativamente equilibradas entre las distintas clases, no fue necesario aplicar estas técnicas en este trabajo.

Finalmente, estos resultados son consistentes con lo observado previamente mediante PCA. Si dos medios presentan documentos cercanos en el espacio de características, es esperable que el clasificador tenga dificultades para diferenciarlos y que aparezcan confusiones entre clases. Por el contrario, medios cuyos documentos forman agrupamientos más separados tienden a producir menores tasas de error y mejores métricas de clasificación. La mejora obtenida al introducir The Hill sugiere que sus artículos presentan características más distintivas respecto a los demás medios considerados.




Figura 13: Matriz de confusión obtenida utilizando Reuters, The Hill y The New York Times.




Figura 14: Matriz de confusión obtenida utilizando CNBC, The Hill y The New York Times.

F. Técnica alternativa de extracción de features

Un método alternativo al ya mencionado es LSA (*latent semantic analysis*). Esta técnica parte de una matriz de *BoW* (documento-palabras únicas), y busca reducir sus dimensiones buscando agrupar las palabras bajo a una misma temática (por ejemplo: futbol, cancha, pelota).

LSA logra una reducción de dimensionalidad de la matriz documento-palabra mediante la *singular value decomposition* (SVD).

La Descomposición en Valores Singulares (SVD) es una técnica de factorización de matrices. Partiendo de una matriz real $X \in \mathbb{R}^{m \times n}$ (por ejemplo, una matriz documento-palabra unica), la SVD la factoriza en tres matrices:

$$X = U \Sigma V^T$$

donde:

- $U \in \mathbb{R}^{m \times r}$ es una matriz ortonormal cuyas columnas se denominan *vectores singulares izquierdos*.
- $\Sigma \in \mathbb{R}^{r \times r}$ es una matriz diagonal que contiene los *valores singulares*, ordenados de mayor a menor.
- $V \in \mathbb{R}^{n \times r}$ es una matriz ortonormal cuyas columnas se denominan *vectores singulares derechos*.
- $r = \text{rango}(X)$.

Los valores singulares en Σ representan la importancia de cada dimensión latente. Los valores más grandes corresponden a direcciones que capturan mayor estructura o varianza en los datos.

En LSA no se utilizan todas las componentes obtenidas por la SVD. En cambio, se conservan únicamente las k componentes asociadas a los mayores valores singulares, obteniendo una aproximación de rango reducido:

$$X \approx U_k \Sigma_k V_k^T$$

donde $k < r$. De esta forma se eliminan componentes asociadas principalmente al ruido y se conserva la información más relevante del corpus.

Cada documento queda representado por un vector de dimensión k , correspondiente a sus coordenadas en este nuevo espacio latente. A diferencia de la representación BoW o TF-IDF, estas nuevas dimensiones no representan palabras individuales, sino conceptos o temas latentes inferidos a partir de los patrones de coocurrencia de las palabras en los documentos.

Por ejemplo, palabras como *football*, *goal*, *stadium* y *player* pueden contribuir fuertemente a una misma dimensión latente relacionada con el deporte, aunque no aparezcan siempre juntas. De forma similar, términos como *stock*, *market*, *investor* y *shares* pueden agruparse en otra dimensión asociada a economía.

Como consecuencia, LSA permite capturar relaciones semánticas entre palabras y documentos, reduciendo el efecto de la sinonimia y de la alta dimensionalidad característica de las representaciones basadas únicamente en frecuencias de términos. Esto suele generar representaciones más compactas y con mayor capacidad para reflejar la similitud semántica entre documentos.

3. Repositorio

El código completo del proyecto está disponible en el siguiente repositorio:
GitHub - Tareas introducción a la Ciencia de Datos

Referencias

- [1] Bag Of Words, <https://www.ibm.com/es-es/think/topics/bag-of-words>
- [2] TF-IDF, <https://www.geeksforgeeks.org/machine-learning/understanding-tf-idf-term-frequency-inverse-docu>
- [3] PCA, <https://apxml.com/courses/nlp-fundamentals/chapter-2-nlp-feature-engineering/dimensionality-reduction-text>
- [4] Multinomial Naive Bayes, <https://www.upgrad.com/blog/multinomial-naive-bayes-explained/>
- [5] LSA, <https://www.ibm.com/think/topics/latent-semantic-analysis>